ACADÉMIE DES MATHÉMATIQUES APPLIQUÉES

PIIA – Cohorte 2 · Spécial Machine Learning

ParaSpeech Africa

Projet fil rouge : des contenus audiovisuels bilingues aux ressources linguistiques africaines

Lancement :	Samedi 26 septembre 2026
Release finale :	Samedi 27 février 2027
Domaines :	Mathématiques appliquées · Data · Signal · ML · Langues africaines

1. Contexte de politique publique

La transformation numérique africaine pose un enjeu central : rendre les services et technologies numériques accessibles à des populations dont les langues quotidiennes restent peu représentées dans les ressources numériques et les systèmes d'intelligence artificielle.

Au **Bénin**, la Stratégie Nationale d'Intelligence Artificielle et des Mégadonnées (SNIAM) 2023–2027 vise des solutions technologiques adaptées aux réalités nationales, notamment dans l'éducation, la santé et l'agriculture, ainsi que le développement des compétences en IA. Le projet public **JaimeMaLangue**, lancé en novembre 2025, organise la collecte de voix en langues béninoises afin de créer des données utiles aux futurs systèmes d'IA. La **Vision Bénin 2060** s'inscrit dans une logique de développement durable et inclusif ; son processus d'appropriation a intégré plusieurs langues nationales.

La même dynamique existe dans la sous-région : la **Côte d'Ivoire** a publié en 2026 une Stratégie Nationale de l'IA ; le **Sénégal** inscrit le numérique dans son New Deal Technologique et la Vision Sénégal 2050 ; le **Togo** lie transformation numérique, inclusion des citoyens et digitalisation des services ; le **Mali** présente l'inclusion comme un principe de sa transformation numérique ; le **Niger** prépare une stratégie nationale d'IA selon une démarche annoncée comme inclusive et adaptée aux réalités locales. À l'échelle continentale, la Stratégie de l'Union africaine promeut une IA africaine, responsable et inclusive.

Point de départ du projet. Des milliers de vidéos africaines – prédications, conférences, formations, cérémonies ou discours – contiennent une structure naturellement bilingue : un locuteur s'exprime, puis un interprète restitue le message dans une autre langue. Ces contenus existent, mais ils ne sont généralement ni segmentés, ni alignés, ni transformés en ressources linguistiques exploitables.

2. Problématique scientifique et produit

Comment transformer semi-automatiquement une vidéo avec interprétation consécutive en un corpus bilingue structuré, segmenté, aligné, évalué et réutilisable ?

Le produit à construire, **ParaSpeech Studio**, doit progressivement réaliser :

Vidéo/Audio → extraction → segmentation → paires candidates → score ML → validation humaine → **corpus bilingue**

Important : le projet ne demande pas de construire immédiatement un système complet de traduction ou d'ASR. L'objectif PIIA est d'abord de résoudre correctement le problème de **construction et d'alignement de données bilingues**.

Repères publics vérifiés : Gouvernement du Bénin (SNIAM 2023–2027 ; JaimeMaLangue), Vision Bénin 2060, ANSSI Côte d'Ivoire, Présidence du Sénégal, Présidence/Ministère du Numérique du Togo, AGETIC Mali, Gouvernement du Niger, Union africaine. Références détaillées en page 5.

3. Objectifs fonctionnels

À la fin du projet, ParaSpeech Studio doit permettre à un utilisateur autorisé de :

1. importer un fichier audio/vidéo ;
2. extraire et normaliser la piste audio ;
3. détecter les zones de parole et de silence ;
4. découper le contenu en segments/tours de parole ;
5. calculer des caractéristiques simples sur les segments ;
6. générer des paires source–interprétation candidates ;
7. attribuer à chaque paire un score de confiance ;
8. faire valider/corriger les paires par un humain ;
9. exporter le corpus et les métadonnées.

Exemple de sortie attendue
`PAIR_0068` · Source 00 :32 :04–00 :32 :15 · Interprétation 00 :32 :16–00 :32 :31 · Durées 11,4 s / 15,1 s · Score 0,92 · Statut : ACCEPTÉ

4. Phase 0 – Lancement : programmation et mathématiques

Période : 26 septembre – début octobre 2026

Les étudiants ont déjà étudié les fondations mathématiques et la programmation. La première version doit donc être construite **sans Machine Learning avancé**.

Travaux obligatoires :

— créer le dépôt GitHub et l'environnement Python ;
— définir une convention de nommage des données ;
— constituer un premier jeu pilote de vidéos autorisées ;
— extraire l'audio d'au moins une vidéo ;
— lire le signal sous Python et visualiser amplitude/durée ;
— construire les premières métadonnées en CSV/JSON.

Outils : Python 3, Git, GitHub, Jupyter, NumPy, Pandas, Matplotlib, FFmpeg.

Structure minimale du dépôt

```
paraspeech/
  data/raw/          data/processed/      data/annotations/
  notebooks/         src/preprocessing/   src/features/
  src/alignment/     src/models/          src/evaluation/
  app/               tests/               README.md
```

5. Phase 1 – Données et modélisation

Période : octobre 2026

La matière audiovisuelle brute doit devenir un dataset exploitable.

Pipeline V1 :

Audio brut → mono/fréquence commune → normalisation → analyse → silences → segmentation → dataset

Mesures simples à exploiter :

$$\bar{x} = \frac{1}{N}\sum_{i=1}^{N} x_i, \qquad \mathrm{Var}(X) = \frac{1}{N}\sum_{i=1}^{N}(x_i - \bar{x})^2$$

$$RMS(x) = \sqrt{\frac{1}{N}\sum_{i=1}^{N} x_i^2}$$

Les étudiants utiliseront notamment : durée, amplitude, énergie/RMS, ratio de silence et Zero Crossing Rate. FFT, spectrogrammes et MFCC peuvent être introduits comme **outils encadrés**, mais ne sont pas des prérequis théoriques à maîtriser pour valider la V1.

Outils : NumPy, Pandas, SciPy, Librosa, SoundFile, FFmpeg, Matplotlib, SQLite/SQL.

6. Phase 2 – Machine Learning supervisé

Période : novembre 2026

Le coeur ML du projet est formulé comme un problème de classification. Pour une paire candidate (S_i, T_j) :

$$Y = \begin{cases} 1 & \text{si } T_j \text{ est l'interprétation de } S_i, \\ 0 & \text{sinon.} \end{cases}$$

Features candidates :

— durée source et cible ; ratio des durées ;

— distance temporelle entre les segments ;

— énergie/RMS et ratio de silence ;

— position relative dans la séquence ;

— changement de locuteur estimé par caractéristiques acoustiques simples.

Avant le ML, les étudiants doivent proposer une **baseline mathématique explicable** :

$$Score = w_1 T + w_2 D + w_3 P + w_4 A$$

avec T = proximité temporelle, D = cohérence des durées, P = ordre dans la séquence et A = compatibilité acoustique.

Ils comparent ensuite, selon les modèles effectivement abordés en cours : régression logistique, KNN, SVM, arbre de décision, Random Forest et/ou Gradient Boosting.

Outil principal : Scikit-learn.

Livrable V2 : classificateur qui attribue à chaque paire candidate une probabilité/score de correspondance, avec modèle sauvegardé et protocole reproductible.

7. Phase 3 – Non supervisé et exploration acoustique

Période : fin novembre – décembre 2026

À partir d'un vecteur de caractéristiques acoustiques X_i, les étudiants expérimentent : PCA, K-Means, DBSCAN et clustering hiérarchique lorsque ces méthodes sont enseignées.

Objectif : vérifier si les segments se structurent naturellement selon des profils acoustiques/locuteurs et utiliser ces observations pour améliorer la génération des paires.

Le Reinforcement Learning étudié dans le PIIA **n'est pas imposé artificiellement** au coeur de ParaSpeech. Une extension facultative peut étudier la décision *auto-accept / human-review / reject*, mais elle ne conditionne pas la réussite du projet.

8. Phase 4 – Évaluation scientifique

Période : décembre 2026 – janvier 2027

Chaque équipe constitue un **Gold Dataset** : un sous-ensemble vérifié manuellement, conservé pour l'évaluation finale.

Métriques : Accuracy, Precision, Recall, F1-score, matrice de confusion, ROC-AUC lorsque pertinente, validation croisée lorsque pertinente.

L'équipe doit surtout produire une **analyse d'erreurs** : résumé de l'interprète, regroupement de phrases, omission, silence mal détecté, segment trop long/court, changement de locuteur mal interprété, bruit, musique ou applaudissements.

9. Phase 5 – Introduction au Deep Learning

Période : janvier 2027

Conformément au caractère introductif du module Deep Learning, les étudiants comparent le meilleur modèle classique à un petit réseau (perceptron/MLP). L'usage de modèles pré-entraînés audio ou ASR est autorisé **uniquement comme extension encadrée ou baseline**, et non comme compétence obligatoire.

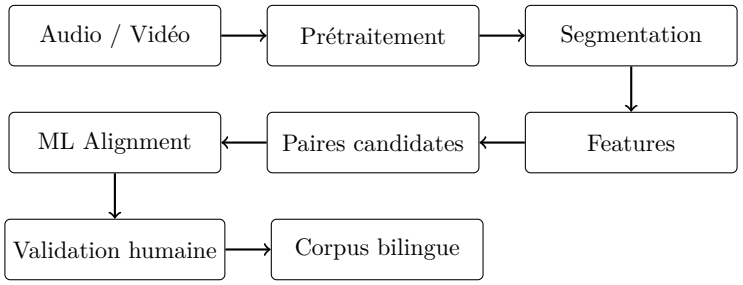
Outils : PyTorch ou TensorFlow/Keras selon le cours.

Livrable V4 : comparaison rigoureuse baseline mathématique vs ML classique vs petite baseline neuronale, avec résultats et limites.

10. Phase 6 – Productisation : ParaSpeech Studio

Période : février 2027

Février sert principalement à intégrer, stabiliser, tester et documenter les briques déjà développées. Les étudiants ne doivent pas dépendre d'un nouveau cours pour terminer le projet.



11. Stack technique

Développement	Python 3, Jupyter, Git, GitHub, environnement virtuel
Données	NumPy, Pandas, CSV, JSON, Parquet, SQLite/SQL
Signal	FFmpeg, SciPy, Librosa, SoundFile
Visualisation	Matplotlib, Seaborn
Machine Learning	Scikit-learn
Deep Learning	PyTorch ou TensorFlow/Keras, seulement après le module correspondant
Prototype produit	Streamlit (template/prise en main fournis si nécessaire)
Évaluation	Scikit-learn Metrics ; outils complémentaires uniquement si justifiés

12. Livrables finaux obligatoires

1. **Repository GitHub** propre, versionné, documenté et reproductible.
2. **Corpus structuré** avec fichiers audio, métadonnées et statut de validation.
3. **Gold Dataset** entièrement vérifié manuellement.
4. **Pipeline de traitement** de la donnée brute aux segments.
5. **Baseline mathématique** d'alignement clairement documentée.
6. **Modèle ML** d'alignement + expériences + métriques.
7. **ParaSpeech Studio** : importer, segmenter, proposer, valider, exporter.
8. **Rapport scientifique** : problème, données, méthodes, mathématiques, expériences, résultats, erreurs, limites, perspectives.
9. **Soutenance** avec démonstration sur un contenu non utilisé pour l'entraînement.

Objectif de données recommandé : viser progressivement au moins 10 h de contenus autorisés analysés à la fin du projet, dont un sous-ensemble Gold réellement vérifié. La qualité et la traçabilité priment sur le volume.

13. Contraintes éthiques et juridiques

— utiliser uniquement des contenus pour lesquels l'usage envisagé est autorisé ;

— documenter la provenance, les droits et les restrictions de chaque source ;

— ne pas republier des médias tiers sans autorisation ;

— respecter la vie privée et éviter toute donnée personnelle inutile ;

— distinguer clairement données brutes, données dérivées et données redistribuables.

14. Planning de référence et critères d'évaluation

Échéance	Version	Résultat attendu
26 sept. 2026	V0 – Kick-off	Repo, protocole de collecte, première vidéo/audio, premières métadonnées
Octobre	V1 – Data Pipeline	Prétraitement, segmentation, statistiques, dataset structuré
Novembre	V2 – ML Alignment	Baseline mathématique, annotation, modèle supervisé, score de confiance
Décembre	V3 – Exploration	PCA/clustering, analyse acoustique, amélioration des features
Janvier 2027	V4 – Évaluation	Gold Dataset, métriques, analyse d'erreurs, petite baseline neuronale
27 fév. 2027	V5 – Release	ParaSpeech Studio, corpus final, rapport, démo et soutenance

Pondération

Qualité, traçabilité et rigueur de la collecte	15%
Mathématiques, traitement des données et du signal	20%
Feature engineering et modélisation ML	20%
Évaluation scientifique et analyse d'erreurs	20%
Qualité fonctionnelle de ParaSpeech Studio	15%
Code, Git, documentation et soutenance	10%

15. Trame recommandée pour la soutenance

La présentation finale doit suivre une logique claire :

Politique publique et inclusion numérique → langues africaines peu dotées → ressources audiovisuelles bilingues inexploitées → problème d'alignement → mathématiques + données + ML → résultats → produit → impact potentiel

Principe pédagogique AMA
À chaque nouveau module du PIIA, l'étudiant ne change pas de problème : il acquiert un nouvel outil scientifique pour mieux résoudre le même problème.
Mathématiques → Programmation → Données → Machine Learning → Évaluation → Deep Learning → Produit

16. Références de cadrage

1. Gouvernement du Bénin – Stratégie Nationale d'Intelligence Artificielle et des Mégadonnées 2023–2027.
2. Gouvernement du Bénin – Projet JaimeMaLangue, 10 novembre 2025.
3. Vision Bénin 2060 – Vision nationale et travaux en langues nationales.
4. ANSSI Côte d'Ivoire – Stratégie Nationale de l'Intelligence Artificielle, 2026.
5. Présidence du Sénégal – New Deal Technologique / Vision Sénégal 2050.
6. Togo – Transformation numérique et inclusion des citoyens.
7. Mali – AGETIC : inclusion et transformation numérique.
8. Niger – Démarche nationale IA inclusive, 2025.
9. Union africaine – Continental Artificial Intelligence Strategy, 2024.
10. Liu, N. – SCIPPC, corpus d'interprétation consécutive chinois–anglais, 19 h 43 min, transcrit et aligné.
11. Duquenne et al. – SpeechMatrix, ACL 2023 : corpus speech-to-speech miné dans 136 paires de langues.