ParaSpeech Africa : De la Parole Bilingue aux Ressources Linguistiques Africaines

Soutenance d'étape : Bilan des Phases 0 & 1 et Cadrage Phase 2

Edjabrou Ulrich Blanchard KABLAM Richnel EGUE
Ghilth GBAGUIDI Wilfried BONOU

Académie des Mathématiques Appliquées (AMA)
Spécialité Machine Learning – Promotion 2026–2027

Octobre 2026

1. Contexte & Verrou Scientifique

Opportunité politique et locale :

- **SNIAM Bénin (2023–2027)** & projet **JaimeMaLangue** : urgence de collecter des corpus vocaux en langues nationales.
- Présence de milliers d'heures de captations en **interprétation consécutive** (discours, cultes, conférences).

Le binôme choisi :

Français $\longleftrightarrow$ Fongbe (Fon)

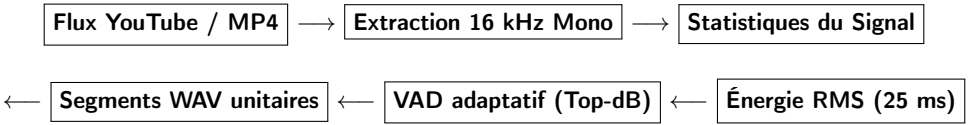
Le Verrou Scientifique PIIA

Transformer semi-automatiquement un flux audiovisuel bilingue non-annoté en un **corpus parallèle segmenté, aligné et réutilisable**.

Objectif clé : Résoudre d'abord le problème géométrique et statistique d'alignement avant les modèles lourds d'ASR.

2. Architecture du Pipeline V1 (Phases 0 & 1)

Le traitement transforme la matière brute en un jeu de segments acoustiques calibrés :



- **Théorème de Shannon-Nyquist :** $f_s = 16\,000\,\text{Hz} \geq 2 \times 4\,000\,\text{Hz}$ (préservation intégrale des formants phonétiques de la parole).
- **Gestion des données :** Fichiers lourds ignorés par Git, métadonnées versionnées en CSV.

3. Démarche Expérimentale : Deux Cas d'Usage Complémentaires

Pour garantir la rigueur méthodologique exigée par l'AMA, deux environnements acoustiques opposés ont été collectés :

Identifiant	Contexte & Profil Acoustique	Rôle dans le projet
VID001 (Studio E-learning)	Son sec, micro cravate, aucun bruit de fond, sous-titres incrustés.	**Étalon d'or (Gold Baseline)** pour calibrer les seuils.
VID002 (Culte Godomey)	Écho de grande salle, sono d'église, réactions de l'assemblée.	**Cas réel de terrain** pour éprouver la robustesse.

Convention de nommage stricte : `[LANG1_LANG2]_[DOMAINE]_[ANNEE]_[ID]`

4. Analyse Statistique du Signal Audio (Phase 1)

Les descripteurs mathématiques fondamentaux calculés sur `VID001` (486,61 s) :

Formulations mathématiques

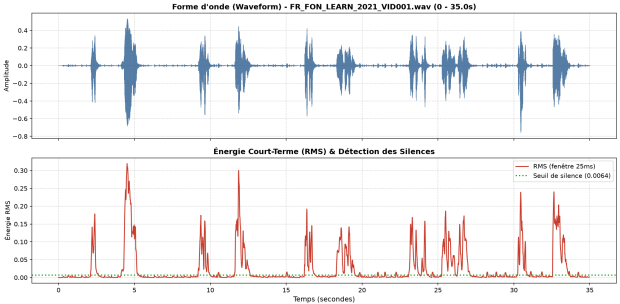
- Offset DC : $\bar{x} = \frac{1}{N}\sum x_i = -8{,}34 \times 10^{-8} \approx 0$
- Variance : $\mathrm{Var}(X) = 0{,}0028$
- Énergie efficace : $\mathrm{RMS} = 0{,}0529$
- Taux passage par zéro : $\mathrm{ZCR} = 0{,}0838$

Interprétation physique

- Signal parfaitement centré (absence de dérive continue).
- ZCR moyen caractéristique de l'alternance voyelles voisées / fricatives.
- Énergie globale suffisante pour discriminer parole et silence.

Environnement	Durée (s)	RMS	ZCR moyen	Segments extraits
Studio (VID001)	486,61	0,0529	0,0838	**127**
Terrain Église (VID002)	99,37	0,1069	0,1221	**10–15**

5. Détection d'Activité Vocale & Alternance Bilingue



- **Alternance temporelle nette :** S_1 (Français : *"Bonjour !"*) $\rightarrow$ Silence $\rightarrow$ T_1 (Fongbe : *"Dóo núwe"*).
- **Résultat de découpage : 127 segments vocaux unitaires** extraits avec succès, sans fausses alertes.

6. Incidents Techniques Résolus (Ingénierie & Acoustique)

Incident rencontré	**Cause racine**	**Solution déployée**
Échec de build `llvmlite` sur macOS Intel	Incompatibilité Python 3.14 (pré-release sans wheels x86_64).	Environnement virtuel verrouillé en **Python 3.11** via `uv`.
Blocage binaire FFmpeg	Homebrew arrêté en *Tier 3* sur l'OS hôte.	Intégration du package autonome `imageio-ffmpeg`.
Sous-segmentation (44 s) et faux silences	Seuil percentile aveugle capturant le souffle du micro.	Algorithme adaptatif **Top-dB (26 dB sous le pic RMS)**.

7. Intégration du Corpus FFR-v1 & Feuille de Route Phase 2

Le rôle pivot de FFR-v1 (Dossou et al.) :

- 117 000 phrases parallèles Français–Fongbe.
- Calibre la loi du **ratio de durée** ($\mu_r \approx 1{,}1$, $\sigma_r \approx 0{,}3$).
- Sert de lexique de référence avec gestion stricte des diacritiques.

Baseline Mathématique Phase 2 :

$$\text{Score}(S_i, T_j) = w_1 T + w_2 D + w_3 P + w_4 A$$

Jalons de Novembre (Phase 2)

1. Génération des paires candidates (S_i, T_j) par fenêtre glissante.
2. Évaluation de la baseline analytique explicable.
3. Entraînement de classificateurs supervisés Scikit-learn (Random Forest, SVM, Régression Logistique).

Phases 0 & 1 validées – Prêts pour la modélisation ML !